Desarrollo de aplicaciones con IA

TÍTULO:

Avance proyecto 2

AUTORES:

Laura Sofia Franco Mateus – 506241128

Karen Marcela Bayona Romero - 506241093

TUTOR:

Leandro Pájaro Fuentes

FUNDACIÓN UNIVERSITARIA KONRAD LORENZ

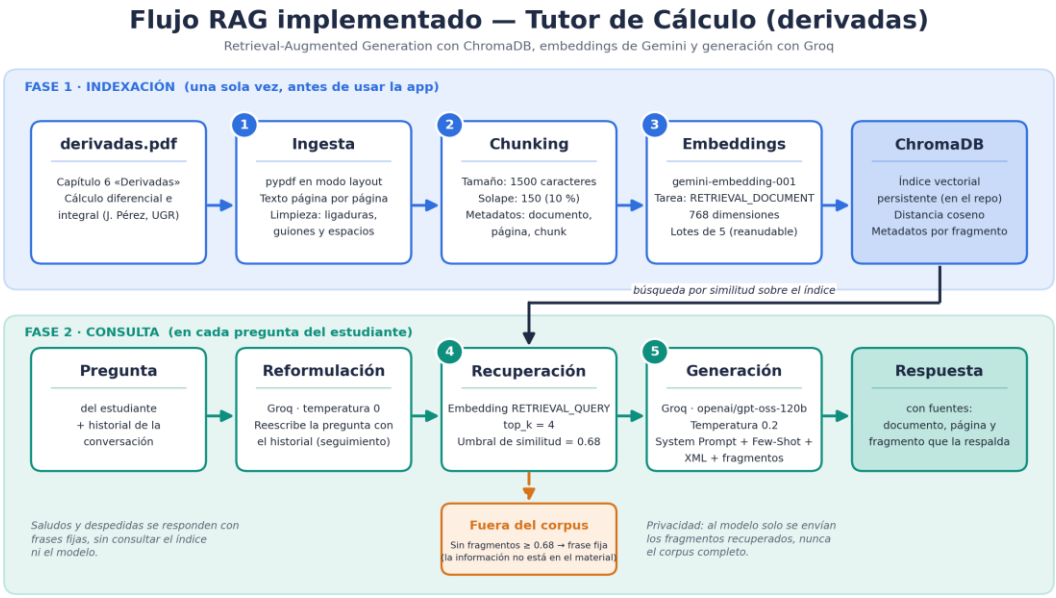
FACULTAD DE INGENIERÍA PREGRADO

BOGOTÁ D.C

2026

Repositorio GitHub: https://github.com/Karen-Bayona/proyectoIA_tutor_calculo1-LauraFranco-KarenBayona/blob/main/rag.py

1. Diagrama del flujo RAG implementado



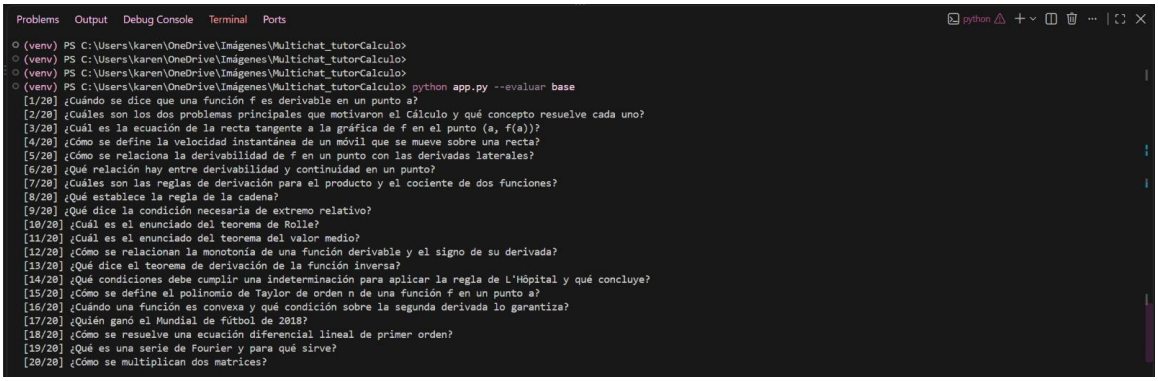
Justification de los parámetros elegidos:

Etapa	Decisión	Justificación
Corpus	derivadas.pdf	Capítulo 6 «Derivadas» de Cálculo diferencial e integral (Prof. Javier Pérez, Universidad de Granada). Contiene definiciones, teoremas, demostraciones y ejercicios resueltos sobre derivabilidad, reglas de derivación, Rolle, valor medio, L'Hôpital, Taylor y convexidad. Se partió de un libro completo de Cálculo 1, pero al indexarlo se agotó la cuota diaria gratuita de la API de incrustaciones de Gemini (el proceso se detenía cerca de 1000), por lo que se acotó el dominio a derivadas. Al ser un único documento acotado, se puede comprobar si cada respuesta está respaldada por el texto.
Ingesta	pypdf texto página por página, con limpieza (ligaduras, guiones de fin de línea, espacios)	Conserva el número de página, necesario para citar la fuente. El modo layout separa mejor las palabras en este PDF que el modo normal.
(chunking)	1500 caracteres, solape 150 (10 %), dentro de cada página; el corte se ajusta al	Un fragmento de este tamaño suele contener un enunciado completo con parte de su contexto o demostración. El solape evita que una definición o fórmula quede cortada en el límite entre fragmentos. Al

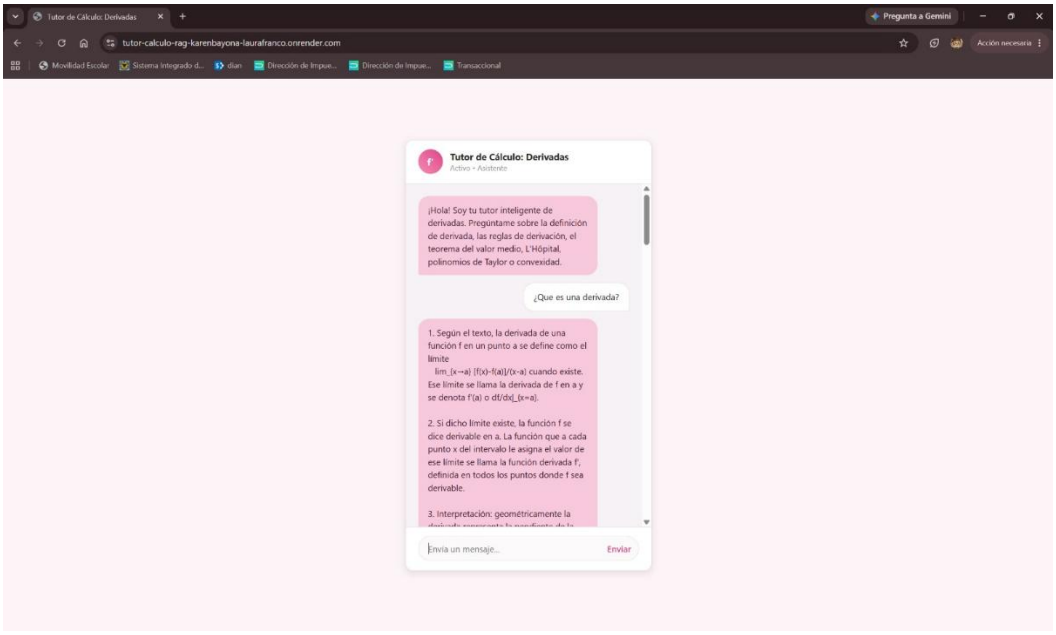
Etapa	Decisión	Justificación
	último punto de la segunda mitad del fragmento si existe	cortar por página, cada fragmento conserva su número de página.
Incrustaciones	gemini-embedding-001, con tipo de tarea RETRIEVAL_DOCUMENT para fragmentos y RETRIEVAL_QUERY para preguntas	Modelo multilingüe pensado para recuperación; distinguir documento y pregunta mejora la coincidencia entre una pregunta corta y un fragmento largo. Se usa por API, sin modelos locales, porque el plan gratuito de Render solo tiene 512 MB de RAM. Vectores de 768 dimensiones. La indexación es por lotes de 5 fragmentos con pausa y es reanudable.
Base vectorial	ChromaDB con PersistentClient, distancia coseno	Persistencia local simple; el índice viaja con el repositorio.
Metadatos	Documento, pagina, chunk	Permiten mostrar la fuente de cada respuesta.
Recuperación	top_k = 4, umbral de similitud 0.68	La similitud mínima de las preguntas del documento fue 0.71 y la máxima de las preguntas fuera del documento fue 0.653; el umbral 0.68 queda en esa brecha y separa ambos grupos. top_k = 4 dio mejor fidelidad que 3.
Generación	Groq (openai/gpt-oss-120b), temperatura 0.2	Genera la respuesta final con la pregunta, el historial y los fragmentos recuperados (con System Prompt y delimitadores XML), y reformula la pregunta con el historial (temperatura 0) antes de buscar. Gemini se usa solo para los incrustaciones. La temperatura baja mantiene la respuesta fiel al texto. Las llamadas se reintentan con espera ante errores temporales; si la reformulación falla se usa la pregunta original.
Preguntas de seguimiento	Historial enviado por el navegador en cada turno, validado y limitado en longitud por el servidor	La pregunta se reformula con ese contexto antes de buscar, para que preguntas como «¿y para qué sirve?» se resuelvan correctamente.
Privacidad	Documentos e índice en el repositorio	Al modelo solo se le envían los fragmentos recuperados para cada consulta, nunca el corpus completo.

2. Capturas de la ejecución de consultas sobre el RAG y análisis de las respuestas:

CAPTURA 1:



CAPTURA 2:



Análisis de las respuestas:

- Respuestas muy largas y con rodeos: El modelo responde con rodeos, usa frases como «Según el texto…» y añade explicaciones de más, lo que baja la nota de evaluación de Ragas.

- Errores de lógica al responder: El modelo se equivoca al redactar: aplicó reglas de los extremos a puntos del medio en derivadas, y agregó detalles inventados en monotonía y L'Hôpital.

- Se recupera relleno innecesario: Traer 4 fragmentos (top_k = 4) mete texto de poco valor (ejercicios y contexto histórico), haciendo que temas como la recta tangente o el teorema de Rolle saquen notas bajas.

- La búsqueda encuentra lo necesario: El sistema sí logra encontrar toda la información clave para responder; la búsqueda en sí no es el problema.

- El PDF está mal cortado y extraído: Hay palabras pegadas, símbolos matemáticos dañados y frases cortadas a la mitad por cortar por caracteres. Hay que cortar por párrafos y limpiar la extracción..

3. Resultados de la evaluación Ragas

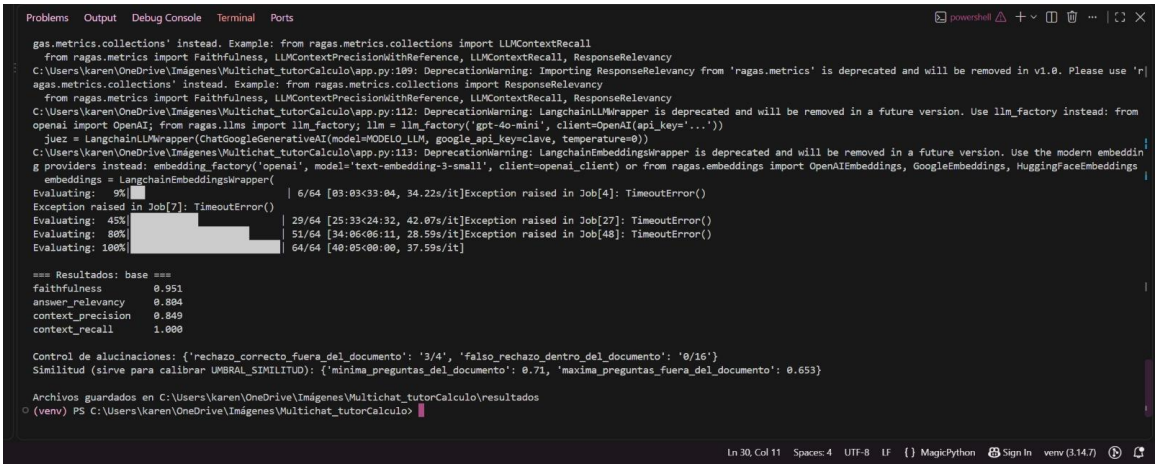
Conjunto de evaluación: preguntas_eval.json, con 20 preguntas y su respuesta de referencia: 16 sobre el documento y 4 fuera del corpus. Las cuatro métricas de Ragas se calculan sobre las 16 preguntas del documento. Las 4 preguntas fuera del corpus miden el control de alucinaciones, y las 16 del documento sirven además para detectar falsos rechazos.

Métricas: faithfulness, answer_relevancy, context_precision y context_recall.

Tabla de métricas

Ejecución	Cambio respecto a la anterior	top_k	Umbral	faithfulness	answer_relevancy	context_precision	context_recall
base	Punto de partida	4	0,45	0,951	0,804	0,849	1.000
umbral068	Umbral 0,45 → 0,68	4	0,68	0,969	0,812	0,850	1.000
mejora2	top_k 4 → 3	3	0,68	0,883	0,809	0,896	1.000

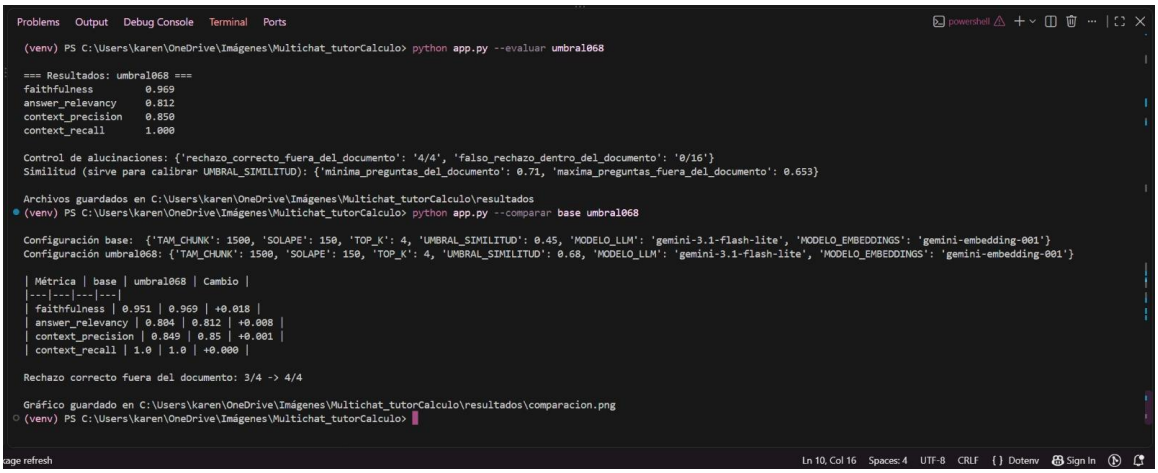
- Parámetros constantes en las tres ejecuciones: chunk 1500, solape 150, gemini-3.1-flash-lite y gemini-embedding-001.
- La captura siguiente muestra la ejecución base de Ragas : 64 evaluaciones (16 preguntas × 4 métricas) en unos 40 minutos, con 4 TimeoutError (trabajos 4, 7, 27 y 48), es decir 4 de 64 valores vacíos (6 %), probablemente por la cuota gratuita del modelo (gemini-3.1-flash-lite, temperatura 0). Se anota como limitación de la evaluación.

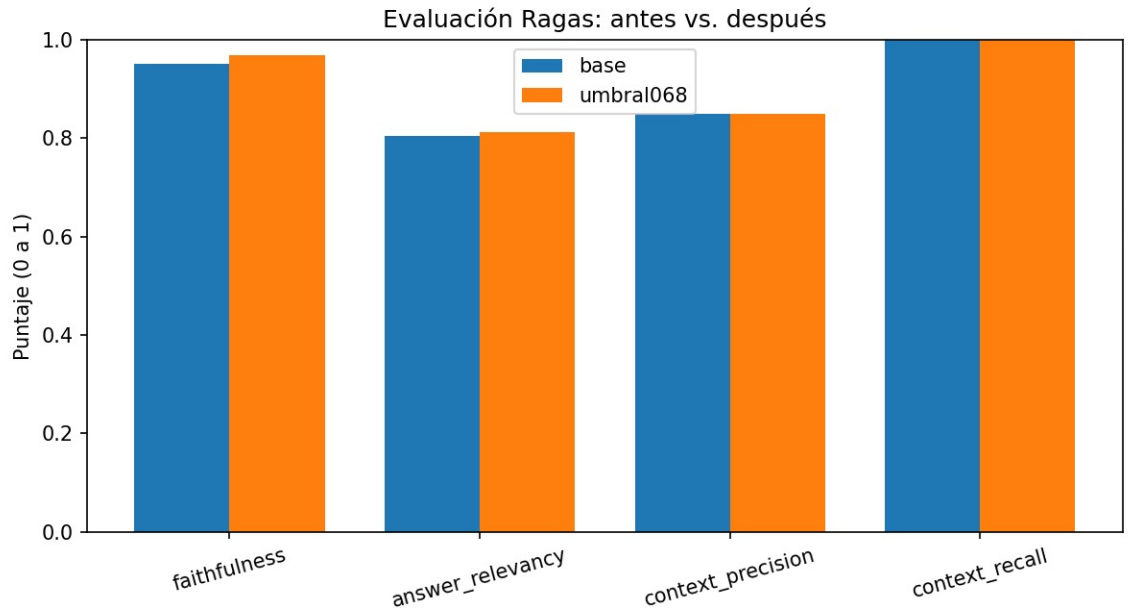


- **Comparación antes/después de la iteración de mejora e interpretación**

Cada métrica se promedia sobre 16 preguntas, por lo que diferencias de alrededor de 0.01. Las diferencias más grandes (control de alucinaciones, faithfulness con top_k = 3 y context_precision) son las que se interpretan. En la ejecución base, Ragas devolvió valor vacío en 2 celdas de faithfulness y 2 de context_recall; los promedios se calculan con las preguntas que sí tienen valor.

- **Iteración 1 (adoptada): umbral de similitud 0.45 → 0.68**
- Motivo: con 0.45, una de las cuatro preguntas fuera del corpus pasaba el filtro y el modelo la respondía (rechazo correcto 3/4). Los datos mostraron una similitud mínima de las preguntas del documento (0.71).
- Resultado: rechazo correcto de 3/4 a 4/4, faithfulness de 0.951 a 0.969, sin falsos rechazos (0/16) y sin pérdida de context_recall.

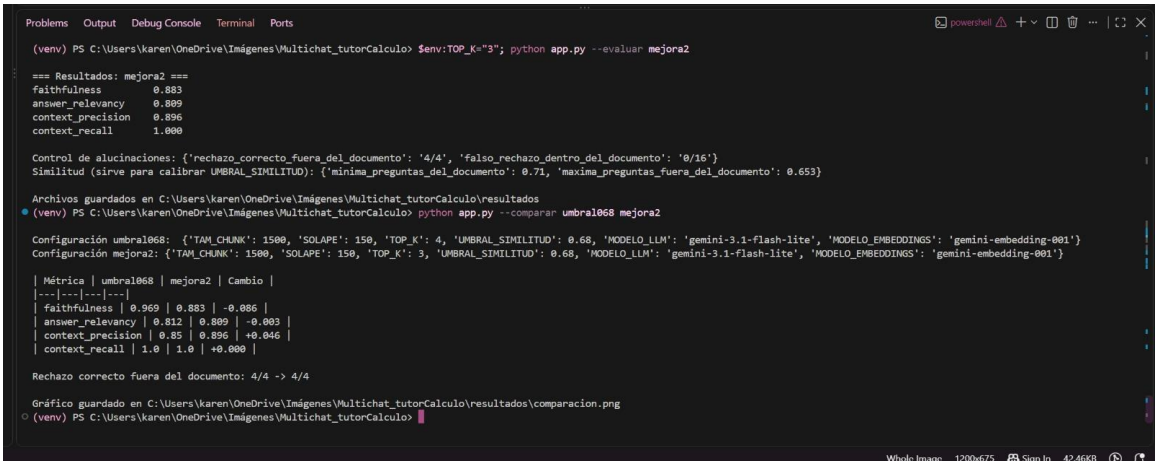


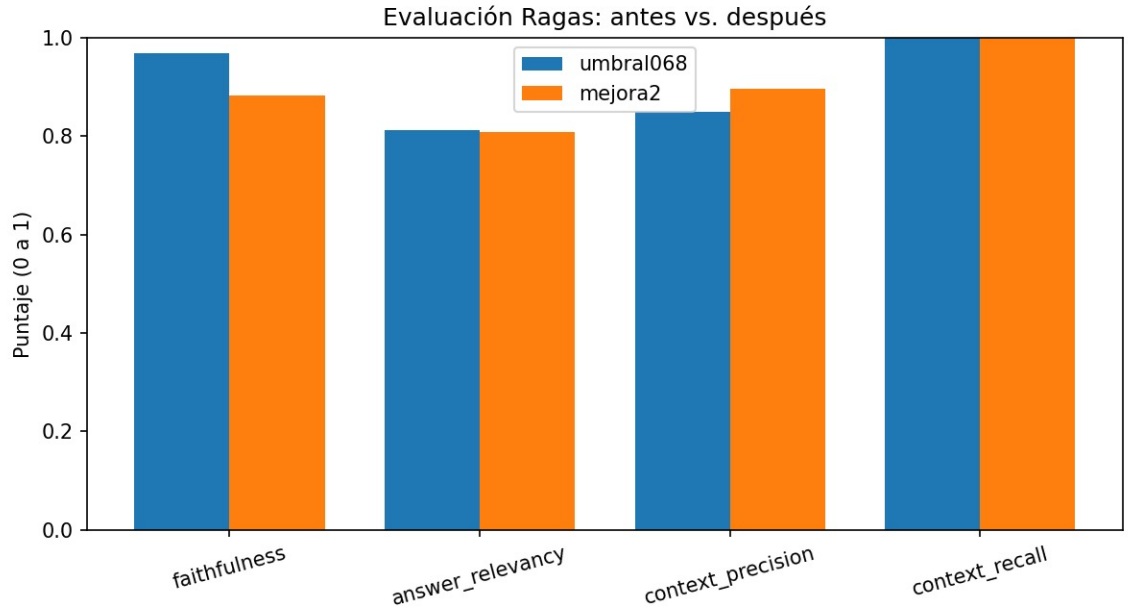


- Interpretación: el único cambio relevante es el control de alucinaciones (3/4 → 4/4). Las diferencias en las métricas Ragas (+0,018 faithfulness, +0,008 answer_relevancy, +0,001 context_precision) son pequeñas y no concluyentes con 16 preguntas.

Iteración 2 (evaluada y descartada): top_k 4 → 3

- Motivo: mejorar context_precision, la métrica atribuida a la recuperación.
- Resultado: context_precision subió de 0.850 a 0.896, pero faithfulness bajó de 0.969 a 0.883. answer_relevancy (0.812 → 0.809), el rechazo (4/4) y context_recall no cambian.
- Decisión: se mantiene top_k = 4, porque en un tutor es más importante que la respuesta se apoye fielmente en el texto que reducir el ruido del contexto.

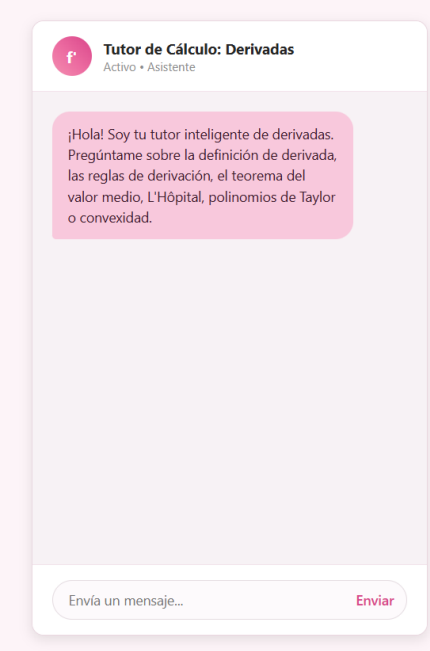
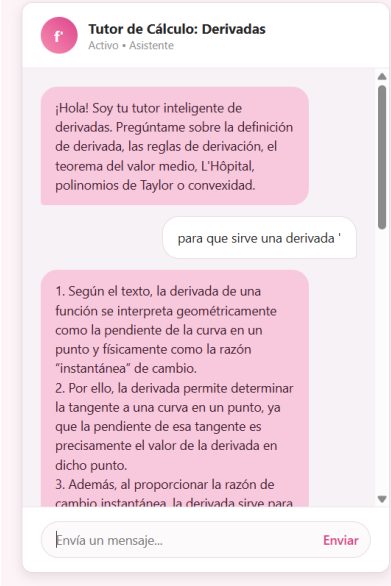




* Interpretación: con top_k = 3 hay menos complejos en el contexto (context_precision +0,046), pero el modelo pierde respaldo y la faithfulness cae 0,086. Por eso se descarta esta iteración y se mantiene top_k = 4.

4. Capturas de la interfaz de chat desplegada

La interfaz de chat está en templates/ y static/ (HTML y CSS). El historial de la conversación vive en el navegador.

CAPTURA 4:	CAPTURA 5:	CAPTURA 6:
		

5. URL pública y repositorio

- **Aplicación desplegada:** https://tutor-calculo-rag-karenbayona-laurafranco.onrender.com
- **Repositorio:** https://github.com/Karen-Bayona/proyectoIA_tutor_calculo1-LauraFranco-KarenBayona